

PREVISÃO DE MOVIMENTOS DO BITCOIN COM REDES NEURAIAS ARTIFICIAIS E INDICADORES TÉCNICOS

Lucas Silva Ciacchi - lucas.ciacchi@alunos.unis.edu.br

Alessandro Ferreira Alves - alessandro.alves@professor.unis.edu.br

Alberane Lucio Thiago da Cunha - alberane.cunha@professor.unis.edu.br

RESUMO

O presente trabalho apresenta uma aplicação de Inteligência Artificial na Análise de Investimentos Financeiros, vivenciada no contexto da pesquisa acadêmica em ciência de dados e mercado de criptomoedas, desenvolvida ao longo dos meses de janeiro a abril de 2025. Através desta pesquisa, busca-se demonstrar a viabilidade do uso de Redes Neurais Artificiais (RNAs) para a previsão da direção do preço do Bitcoin (BTC-USD), com base em indicadores técnicos calculados a partir de dados históricos. Para tanto, foram coletados dados diários dos últimos dois anos por meio da biblioteca `yfinance`, aplicando-se indicadores como Média Móvel Simples (SMA), Média Móvel Exponencial (EMA), Índice de Força Relativa (RSI), Volatilidade (desvio padrão) e Média Móvel do Volume. Esses dados foram então utilizados como variáveis de entrada para treinar um modelo de RNA capaz de classificar os movimentos de preço como "subiu" ou "desceu". O modelo foi avaliado com base em métricas de desempenho como acurácia, precisão, recall e matriz de confusão, obtendo uma taxa de acerto de aproximadamente 54%. Apesar dos desafios enfrentados, os resultados apontam para a possibilidade de utilizar redes neurais como ferramentas de apoio à tomada de decisão no contexto financeiro. Acredita-se que os resultados deste relato possam contribuir para o debate e reflexões sobre o uso de técnicas de aprendizado de máquina no mercado de criptoativos e seu impacto na construção de estratégias de investimento mais robustas.

Palavras-chave:

Bitcoin. Inteligência Artificial. Redes Neurais. Indicadores Técnicos. Prevenção de Preço

1 INTRODUÇÃO

A volatilidade do mercado financeiro torna a previsão de seus movimentos um desafio constante para investidores e analistas. Métodos tradicionais, como a análise técnica e fundamentalista, são amplamente utilizados, mas apresentam limitações ao tentar captar padrões complexos e variáveis não lineares que influenciam os preços dos ativos. Com o avanço da Inteligência Artificial, o uso de aprendizado de máquina emergiu como uma alternativa promissora para a análise e previsão de tendências no mercado financeiro, incluindo ativos voláteis como criptomoedas.

O aprendizado supervisionado, em particular, tem sido amplamente aplicado para identificar padrões em grandes volumes de dados históricos, fornecendo previsões mais precisas e auxiliando na tomada de decisões estratégicas. Algoritmos como regressão logística, árvores de decisão e redes neurais artificiais (RNAs) têm sido explorados para prever a direção dos preços de ativos, com base em variáveis como volume de negociação, médias móveis e indicadores de força relativa.

Diante desse cenário, este estudo tem como objetivo desenvolver e avaliar modelos de aprendizado supervisionado — com foco em redes neurais — para prever movimentos no mercado financeiro, utilizando indicadores técnicos aplicados ao Bitcoin (BTC-USD) e técnicas de pré-processamento de dados. A pesquisa busca responder à seguinte questão central: "Como classificadores supervisionados, em especial redes neurais, podem prever tendências de ativos financeiros altamente voláteis?"

A importância deste estudo se justifica pela crescente demanda por estratégias automatizadas e embasadas em dados para a tomada de decisão no setor financeiro. Ao desenvolver um modelo preditivo eficiente para criptomoedas, espera-se contribuir para a melhoria das estratégias de investimento, reduzindo riscos e maximizando retornos em um mercado conhecido por sua imprevisibilidade.

2 REFERENCIAL TEÓRICO

2.1. Aprendizado de Máquina no Mercado Financeiro

O avanço das tecnologias computacionais tem permitido o uso de aprendizado de máquina para resolver problemas complexos em diversas áreas, incluindo o mercado financeiro. Segundo Medeiros e Veiga (2019), algoritmos supervisionados têm demonstrado eficácia na previsão de retornos tanto em mercados tradicionais quanto em criptomoedas, superando abordagens tradicionais em termos de precisão e adaptabilidade.

O aprendizado supervisionado consiste em treinar modelos a partir de conjuntos de dados rotulados, permitindo que o algoritmo aprenda padrões e faça previsões baseadas nesses dados. Dentre os principais classificadores utilizados na previsão do mercado financeiro, destacam-se:

- **Regressão Logística:** Modelo estatístico amplamente utilizado para prever probabilidades de eventos binários, como alta ou queda de preços.
- **Árvores de Decisão:** Estruturas hierárquicas que segmentam dados com base em critérios de decisão, facilitando a interpretação dos resultados.
- **Redes Neurais Artificiais:** Modelos inspirados no funcionamento do cérebro humano, especialmente eficazes para capturar não-linearidades em ativos voláteis como o Bitcoin (Silva e Araújo, 2017).

Estudos recentes indicam que a combinação desses algoritmos pode gerar resultados ainda mais precisos na previsão de ativos financeiros (Silva e Araújo, 2017).

2.2. Indicadores Financeiros Relevantes para Modelagem Preditiva

A seleção de indicadores financeiros desempenha um papel crucial na qualidade das previsões geradas pelos modelos de machine learning. Conforme Nomad Invest, determinados indicadores possuem maior impacto na análise de tendências de mercado, sendo amplamente aplicáveis inclusive a criptomoedas. Entre os principais indicadores utilizados estão:

- **Médias Móveis (SMA, EMA):** indicadores que suavizam as flutuações de preços para identificar tendências de alta ou baixa.
- **Volume de Negociação:** mede a intensidade das transações de um ativo e pode sinalizar mudanças iminentes no mercado.

- **Índice de Força Relativa (RSI):** indica se um ativo está sobrecomprado ou sobrevendido, crítico para ativos com alta volatilidade.
- **Volatilidade (desvio padrão):** métrica essencial para avaliar riscos em mercados não lineares (Assaf Neto, 2021).

A correta seleção e ponderação desses indicadores são essenciais para a eficácia dos modelos preditivos. Trabalhos como o de Assaf Neto (2021) destacam a necessidade de uma análise criteriosa dos indicadores para evitar viés excessivo e garantir previsões confiáveis.

2.3. Aplicações Práticas de Algoritmos Supervisionados

Diversos estudos têm explorado a aplicação de aprendizado supervisionado na previsão de preços de ativos digitais e tradicionais. Um exemplo prático é o estudo disponibilizado no GitHub, que implementou modelos de machine learning para prever a movimentação do Ibovespa e criptomoedas, utilizando redes neurais e SVMs. Os resultados indicaram que modelos bem ajustados podem atingir altas taxas de acurácia ao prever tendências de curto prazo (GitHub, 2020).

Além disso, o uso de aprendizado supervisionado não se limita apenas à previsão de preços, mas também pode ser aplicado para análise de risco em cenários de alta volatilidade, detecção de fraudes e otimização de carteiras de investimento. Segundo Chan e Wong (2020), algoritmos supervisionados são cada vez mais utilizados por fundos de investimento e plataformas de trading automatizado, devido à sua capacidade de processar grandes volumes de dados e identificar padrões ocultos no comportamento do mercado.

3 MATERIAIS E MÉTODOS

A construção deste estudo se fundamenta em uma abordagem quantitativa e experimental, utilizando técnicas de aprendizado supervisionado para testar a viabilidade da previsão de movimentos do Bitcoin (BTC-USD). O projeto foi desenvolvido de forma simplificada, focando na implementação de um modelo básico de rede neural artificial para analisar dados históricos deste ativo digital.

A pesquisa utilizou dados secundários obtidos de bases públicas, como Yahoo Finance (via API yfinance), que fornece informações históricas sobre preços e indicadores financeiros. O período analisado abrange os últimos dois anos (2023-2025), com dados diários para capturar padrões relevantes.

3.1 Coleta de Dados

A coleta de dados será realizada por meio da biblioteca yfinance, que permite obter informações do Bitcoin (BTC-USD) diretamente do Yahoo Finance. Serão coletadas as seguintes variáveis:

- **Preço de fechamento diário**
- **Volume de negociação**
- **Médias móveis (SMA, EMA)**
- **Índice de Força Relativa (RSI)**
- **Volatilidade (desvio padrão de 14 dias)**
- **Volume Médio (14 dias)**

A seleção dessas variáveis se baseia na literatura que aponta sua relevância para previsão de tendências de mercado (Nomad Invest, 2023), com adaptações para criptomoedas.

3.2 Preparação e Limpeza dos Dados

A preparação dos dados é uma etapa essencial para garantir a qualidade do modelo preditivo. As seguintes técnicas serão aplicadas:

- **Remoção de valores ausentes (com drop())**, caso existam falhas nos dados históricos.
- **Normalização dos dados**, utilizando Min-Max Scaling (escala 0-1), para garantir que todas as variáveis fiquem na mesma escala (todas as variáveis numéricas).
- **Seleção de variáveis relevantes**, priorizando indicadores que possuem maior impacto na previsão de preços (Silva e Araújo, 2017).
- **Criação da variável alvo binária (Target)**: 1 se o preço subiu no dia seguinte, 0 caso contrário.

Como o foco do estudo é um modelo mais simples, não serão aplicadas técnicas avançadas de engenharia de atributos ou otimizações complexas.

3.3 Construção do Modelo Supervisionado

O modelo preditivo foi desenvolvido utilizando redes neurais artificiais com Tensor Flow/Keras, por sua eficácia na identificação de padrões não lineares (Medeiros e Veiga, 2019). A arquitetura incluirá:

- **Uma camada de entrada**, correspondente ao número de variáveis de entrada.
 - 6 neurônios (correspondentes às variáveis de entrada).
- **Duas camadas ocultas**, utilizando poucas unidades para evitar o overfitting.
 - 64 neurônios (ReLU) + Dropout de 20%
 - 32 neurônios (ReLU)
- **Uma camada de saída**, com ativação sigmoide, para prever se o preço do ativo terá tendência de alta ou baixa.
 - 1 neurônio sigmoide para classificação binária
- **Compilação:** Otimizador Adam, função de perda *binary cross entropy*, métrica de acurácia.

3.4 Divisão dos Dados em Conjuntos de Treinamento e Teste

Para avaliar o desempenho do modelo, os dados serão divididos em:

- **70% para Treinamento** → Conjunto utilizado para ajustar os pesos do modelo.
- **30% para Teste** → Conjunto usado para avaliar a precisão das previsões.
- **Validação implícita** → 20% dos dados de treino serão usados para validação durante o treinamento.

Não serão utilizadas técnicas avançadas de validação cruzada neste estudo, pois o objetivo é obter resultados exploratórios iniciais.

3.5 Métricas de Avaliação

Para medir o desempenho do modelo, serão utilizadas métricas simples e interpretáveis:

- **Acurácia:** Percentual de previsões corretas.
- **Matriz de Confusão:** Para visualizar os acertos e erros do modelo.
- **Relatório de classificação** (precisão, recall, F1-score).

Essas métricas permitirão avaliar se o modelo consegue captar padrões no mercado financeiro e se pode ser melhorado em pesquisas futuras (Chan e Wong, 2020).

3.6 Ferramentas Utilizadas

O projeto será implementado em Python (3.11), utilizando:


- **yfinance** → Para coleta de dados financeiros.
- **Pandas e NumPy** → Para manipulação dos dados.
- **TensorFlow/Keras** → Para construção da rede neural.
- **Matplotlib e Seaborn** → Para análise visual dos resultados.

4 RESULTADO E DISCUSSÃO

Durante a experiência, foi conduzido um experimento com Redes Neurais Artificiais (RNA) para a previsão de movimento de preços do ativo Bitcoin (BTC-USD), com base em indicadores técnicos previamente definidos: Média Móvel Simples (SMA), Média Móvel Exponencial (EMA), Índice de Força Relativa (RSI), Volatilidade (desvio padrão dos preços) e Média Móvel do Volume. O objetivo foi classificar se, no dia seguinte, o preço do ativo subiria ou cairia, a partir de dados históricos dos últimos dois anos.

Após o treinamento e validação do modelo, os resultados obtidos foram avaliados por meio da matriz de confusão e do relatório de classificação, ferramentas fundamentais para entender o desempenho preditivo do algoritmo.

Figura 1: Matriz de Confusão da Classificação dos Movimentos do Bitcoin



Fonte: o autor

A matriz de confusão apresentada revela que o modelo foi capaz de prever corretamente 47 instâncias em que o preço do Bitcoin caiu (classe 0) e 31 instâncias em que o preço subiu (classe 1). No entanto, houve 66 classificações incorretas (26 falsos positivos + 40 falsos negativos), evidenciando uma dificuldade do modelo em distinguir com precisão os padrões que antecedem uma alta no preço.

Tabela 1: Relatório de Desempenho do Modelo de Classificação

Relatório de Classificação				
	precision	recall	f1-score	support
0	0.54	0.64	0.59	73
1	0.54	0.44	0.48	71
accuracy			0.54	144
macro avg	0.54	0.54	0.54	144
weighted avg	0.54	0.54	0.54	144

Fonte: o autor

O relatório de classificação fornece uma visão quantitativa mais detalhada, com os seguintes destaques:

- A **acurácia total do modelo foi de 54%**, indicando que, em média, pouco mais da metade das previsões foram corretas.
- A **classe 0 (queda)** apresentou **maior recall (0.64)**, o que significa que o modelo identificou corretamente a maioria dos dias em que o ativo caiu. Porém, sua precisão foi apenas moderada (0.54), refletindo um número significativo de falsos positivos.
- A **classe 1 (alta)** obteve uma precisão semelhante (0.54), mas com um recall mais baixo (0.44), mostrando que o modelo teve maior dificuldade para identificar corretamente os dias de alta.
- O **F1-score**, que representa o equilíbrio entre precisão e recall, foi de **0.59 para a classe 0 e 0.48 para a classe 1**, reforçando a assimetria no desempenho entre as duas classes.

Esse desempenho pode ser explicado por características próprias do mercado de criptoativos, que é altamente volátil, sensível a fatores externos e com padrões muitas vezes não lineares. Apesar da utilização de indicadores técnicos consolidados, o comportamento do Bitcoin ainda apresenta aspectos complexos que desafiam a modelagem preditiva com

métodos supervisionados simples.

Uma tendência observada ao longo da experiência foi a melhor capacidade do modelo em prever movimentos de queda, o que pode estar relacionado a uma maior regularidade estatística nos padrões de recuo dos preços, enquanto os momentos de valorização podem ser mais imprevisíveis ou dependentes de fatores externos não considerados nos dados.

Em comparação com as expectativas iniciais, os resultados obtidos foram modestos, indicando que há espaço para aprimoramento tanto nos dados quanto na modelagem, seja com inclusão de novos indicadores, tratamento de desequilíbrio de classes ou ajuste de hiperparâmetros da RNA. No entanto, o fato do modelo superar a aleatoriedade (acima de 50% de acurácia) já é um indicativo de que há potencial na abordagem adotada.

Outro aspecto que merece destaque é que, apesar da limitação no desempenho, o modelo serve como uma base promissora para aplicações práticas, como sistemas de apoio à decisão em investimentos, especialmente se combinado com outras fontes de informação ou modelos complementares.

Os resultados obtidos nesta etapa trazem importantes reflexões sobre os desafios e possibilidades do uso de inteligência artificial no mercado financeiro. A seguir, nas Considerações Finais, são discutidas as implicações dos achados para futuros estudos e melhorias na abordagem.

5 CONSIDERAÇÕES FINAIS

Retomando o objetivo deste trabalho, buscou-se desenvolver um modelo de Inteligência Artificial, mais especificamente uma Rede Neural Artificial (RNA), com o propósito de prever a direção do movimento diário do Bitcoin (BTC-USD) — se o preço subiria ou cairia — com base em dados históricos e indicadores técnicos do mercado financeiro.

A partir da coleta e processamento de dados dos últimos dois anos, foi possível treinar e avaliar um modelo de classificação binária. Os resultados demonstraram uma acurácia de 54%, com maior eficiência na previsão de quedas do ativo, conforme evidenciado pelas métricas de recall e F1-score da classe correspondente. Ainda que o desempenho não tenha sido expressivo, o modelo conseguiu superar a aleatoriedade, o que já é um indicativo de que

há sinais relevantes nos dados captados pelos indicadores técnicos utilizados.

Pode-se afirmar que a experiência proporcionou uma visão concreta dos desafios da aplicação de redes neurais no contexto financeiro, especialmente diante da alta volatilidade e complexidade do mercado de cripto ativos. O modelo demonstrou limitações na identificação de padrões relacionados a movimentos de alta, o que evidencia a necessidade de ajustes e aprimoramentos tanto na parte de dados quanto na estrutura do modelo.

Dentre as melhorias identificadas como promissoras para elevar a eficácia da técnica, destacam-se:

- A **expansão do período de coleta de dados históricos** para além dos dois anos utilizados, o que pode fornecer à rede um conjunto mais robusto e diversificado de padrões comportamentais.
- A **revisão e ampliação dos indicadores técnicos**, com possibilidade de inclusão de novos indicadores e ajustes finos nos parâmetros dos já utilizados.
- O **refinamento da arquitetura do modelo de RNA**, com a experimentação de diferentes quantidades de camadas, neurônios, funções de ativação e ajustes dos hiperparâmetros como epochs e batch size.
- A **adoção de estratégias para balanceamento das classes**, de modo a reduzir o viés do modelo para uma das direções (queda ou alta).
- A possibilidade de **integração de variáveis externas ao modelo**, como notícias de mercado ou dados macroeconômicos, pode enriquecer a capacidade preditiva da rede.

Este estudo, portanto, constitui um ponto de partida relevante para o uso de inteligência artificial na tomada de decisões financeiras, demonstrando que, apesar das limitações enfrentadas, é viável utilizar técnicas de aprendizado de máquina para capturar padrões de comportamento no mercado de ativos digitais.

Fica evidente, contudo, que o aprimoramento contínuo dos métodos, dados e algoritmos é essencial para que se alcance resultados mais expressivos e aplicáveis em cenários reais. O presente trabalho abre espaço para estudos futuros mais amplos, que poderão explorar abordagens híbridas, integrar novas fontes de dados e aplicar validações mais rigorosas, contribuindo significativamente para o avanço desta linha de pesquisa.

BITCOIN PRICE MOVEMENT FORECASTING USING ARTIFICIAL NEURAL NETWORKS AND TECHNICAL INDICATORS

ABSTRACT

This study presents the application of Artificial Intelligence in Financial Investment Analysis, developed in the academic research context involving data science and the cryptocurrency market, during the months of January to April 2025. The objective of this research is to demonstrate the feasibility of using Artificial Neural Networks (ANNs) to predict the direction of Bitcoin (BTC-USD) price movements based on historical data and technical indicators. Daily price and volume data from the last two years were collected using the yfinance library, and the following indicators were calculated: Simple Moving Average (SMA), Exponential Moving Average (EMA), Relative Strength Index (RSI), price Volatility (standard deviation), and Volume Moving Average. These features were used as input for training a classification model to predict whether the next day's price would go up or down. The model was evaluated using accuracy, precision, recall, F1-score, and a confusion matrix, achieving an accuracy of approximately 54%. Despite limitations, the results suggest that neural networks can be valuable tools to support investment decision-making. This study contributes to the ongoing discussion around the application of machine learning in the financial market, particularly in the development of predictive strategies for cryptocurrencies.

Palavras-chave:

Bitcoin. Artificial Intelligence. Neural Networks. Technical Indicators. Price Prediction

REFERÊNCIAS

ASSAF NETO, Alexandre. *Mercado Financeiro*. 12. ed. São Paulo: Atlas, 2021.

BOLLEN, J.; MAO, H.; ZENG, X. *Twitter mood predicts the stock market*. *Journal of Computational Science*, v. 2, n. 1, p. 1-8, 2011.

CHAN, N. T.; WONG, M. C. *Machine learning for algorithmic trading: Prediction of stock price direction using support vector machines*. *Journal of Finance and Data Science*, v. 6, n. 1, p. 1-20, 2020.

DINHEIRO NA PRÁTICA. *Algoritmos de IA que estão mudando o mercado financeiro*. 2023. Disponível em: <https://dinheironapratica.com.br/blog/algoritmos-de-ia-que-estao-mudando-o-mercado-financieiro/>. Acesso em: 17 fev. 2025.

GITHUB. *Previsão do movimento do Ibovespa*. 2023. Disponível em: <https://github.com/odiegopereira/previsao-mercado-acoes-machine-learning>. Acesso em: 17 fev. 2025.

MEDEIROS, Marcelo C.; VEIGA, Álvaro. *Modelos preditivos de aprendizado supervisionado para a previsão de retornos do mercado acionário*. *Revista Brasileira de Economia*, v. 73, n. 4, p. 557-580, 2019.

MURPHY, John J. *Technical Analysis of the Financial Markets: A Comprehensive Guide to Trading Methods and Applications*. New York: New York Institute of Finance, 1999.

NOMAD INVEST. *6 Índices financeiros para investidores da Bolsa*. 2023. Disponível em: <https://www.nomadglobal.com/invest/artigos/conheca-6-indices-financeiros-relevantes-para-investidores-da-bolsa>. Acesso em: 17 fev. 2025.

SILVA, A. F.; ARAÚJO, A. O. *Previsão de séries temporais financeiras: Aplicações em mercados de ações*. *Revista de Economia e Administração*, v. 16, n. 1, p. 23-38, 2017.

ZAMBON, Ricardo C.; MANZATO, Marcos G. *Aprendizado de Máquina na Prática com Python e Scikit-Learn*. São Paulo: Casa do Código, 2019.