

# **PREVISÃO DE MOVIMENTOS DO BITCOIN COM REDES NEURAIIS ARTIFICIAIS E INDICADORES TÉCNICOS**

## **RESUMO**

O presente trabalho apresenta uma aplicação de Inteligência Artificial na Análise de Investimentos Financeiros, vivenciada no contexto da pesquisa acadêmica em ciência de dados e mercado de criptomoedas, desenvolvida ao longo dos meses de janeiro a abril de 2025. Através desta pesquisa, busca-se demonstrar a viabilidade do uso de Redes Neurais Artificiais (RNAs) para a previsão da direção do preço do Bitcoin (BTC-USD), com base em indicadores técnicos calculados a partir de dados históricos. Para tanto, foram coletados dados diários dos últimos dois anos por meio da biblioteca yfinance, aplicando-se indicadores como Média Móvel Simples (SMA), Média Móvel Exponencial (EMA), Índice de Força Relativa (RSI), Volatilidade (desvio padrão) e Média Móvel do Volume. Esses dados foram então utilizados como variáveis de entrada para treinar um modelo de RNA capaz de classificar os movimentos de preço como "subiu" ou "desceu". O modelo foi avaliado com base em métricas de desempenho como acurácia, precisão, recall e matriz de confusão, obtendo uma taxa de acerto de aproximadamente 54%. Apesar dos desafios enfrentados, os resultados apontam para a possibilidade de utilizar redes neurais como ferramentas de apoio à tomada de decisão no contexto financeiro. Acredita-se que os resultados deste relato possam contribuir para o debate e reflexões sobre o uso de técnicas de aprendizado de máquina no mercado de criptoativos e seu impacto na construção de estratégias de investimento mais robustas.

### **Palavras-chave:**

Mercado de criptoativos. Inteligência Artificial. Médias Móveis. Volume de Negociação. Volatilidade. RSI. Prevenção de Preço.

## **1 INTRODUÇÃO**

A volatilidade do mercado financeiro torna a previsão de seus movimentos um desafio constante para investidores e analistas. Métodos tradicionais, como a análise técnica e

fundamentalista, são amplamente utilizados, mas apresentam limitações ao tentar captar padrões complexos e variáveis não lineares que influenciam os preços dos ativos. Com o avanço da Inteligência Artificial, o uso de aprendizado de máquina emergiu como uma alternativa promissora para a análise e previsão de tendências no mercado financeiro, incluindo ativos voláteis como criptomoedas (REN et al., 2022; DINHEIRO NA PRÁTICA, 2023).

O aprendizado supervisionado, em particular, tem sido amplamente aplicado para identificar padrões em grandes volumes de dados históricos, fornecendo previsões mais precisas e auxiliando na tomada de decisões estratégicas. Algoritmos como regressão logística, árvores de decisão e redes neurais artificiais (RNAs) têm sido explorados para prever a direção dos preços de ativos, com base em variáveis como volume de negociação, médias móveis e indicadores de força relativa.

Diante desse cenário, este estudo tem como objetivo desenvolver e avaliar modelos de aprendizado supervisionado — com foco em redes neurais — para prever movimentos no mercado financeiro, utilizando indicadores técnicos aplicados ao Bitcoin (BTC-USD) e técnicas de pré-processamento de dados. A pesquisa busca responder à seguinte questão central: "Como classificadores supervisionados, em especial redes neurais, podem prever tendências de ativos financeiros altamente voláteis?"

A importância deste estudo se justifica pela crescente demanda por estratégias automatizadas e embasadas em dados para a tomada de decisão no setor financeiro. Ao desenvolver um modelo preditivo funcional para criptomoedas, espera-se contribuir para o avanço da aplicação de técnicas de aprendizado de máquina no contexto da análise financeira.

## **2 REFERENCIAL TEÓRICO**

### **2.1. Aprendizado de Máquina no Mercado Financeiro**

O avanço das tecnologias computacionais tem permitido o uso de aprendizado de máquina para resolver problemas complexos em diversas áreas, incluindo o mercado financeiro. Segundo Ren et al. (2022), técnicas supervisionadas têm demonstrado grande potencial na modelagem de comportamentos de ativos financeiros, especialmente em mercados voláteis como o de criptomoedas.

O aprendizado supervisionado consiste em treinar modelos a partir de conjuntos de dados

rotulados, permitindo que o algoritmo aprenda padrões e faça previsões com base neles. Dentre os principais classificadores utilizados na previsão de tendências de mercado, destacam-se:

- **Regressão Logística:** Modelo estatístico utilizado para prever probabilidades de eventos binários, como alta ou queda de preços;
- **Árvores de Decisão:** Estruturas hierárquicas que segmentam dados com base em critérios de decisão, facilitando a interpretação;
- **Redes Neurais Artificiais (RNAs):** Modelos inspirados no funcionamento do cérebro humano, eficazes para capturar relações não lineares (GÉRON, 2019).

Estudos recentes, como o de Liu et al. (2023), mostram que modelos de aprendizado de máquina, mesmo simples, podem apresentar desempenho razoável na previsão de retornos de criptomoedas, reforçando a utilidade dessas abordagens no setor financeiro.

## 2.2. Indicadores Financeiros Relevantes para Modelagem Preditiva

A escolha dos indicadores utilizados como variáveis de entrada é crucial para a qualidade das previsões em modelos de aprendizado supervisionado. Conforme apresentado por Nomad Invest (2023), certos indicadores possuem forte correlação com movimentos de mercado e são amplamente utilizados em estratégias de análise técnica. Entre os principais, destacam-se:

- **Médias Móveis (SMA, EMA):** Suavizam flutuações de preços para indicar tendências de curto e médio prazo;
- **Volume de Negociação:** Ajuda a identificar a força de um movimento de preço;
- **Índice de Força Relativa (RSI):** Mede condições de sobrecompra ou sobrevenda;
- **Volatilidade (desvio padrão):** Reflete o risco associado à instabilidade do ativo.

Esses conceitos são amplamente abordados em obras clássicas da análise técnica, como a de Murphy (1999), e ainda hoje sustentam a construção de modelos baseados em dados técnicos no mercado financeiro.

## **2.3. Aplicações Práticas de Algoritmos Supervisionados**

Vários estudos têm demonstrado o uso prático de aprendizado supervisionado na previsão de preços de ativos financeiros. Liu et al. (2023), por exemplo, aplicaram modelos de machine learning em um portfólio de mais de 3.000 criptomoedas e obtiveram retorno diário superior ao benchmark, mesmo reconhecendo limitações de previsibilidade.

Além disso, projetos aplicados como o do repositório GitHub (2023) mostram que modelos simples, quando bem estruturados, podem atingir resultados consistentes em tarefas preditivas envolvendo índices como o Ibovespa e criptomoedas. Isso reforça que a viabilidade técnica da aplicação de RNAs e outros algoritmos não depende necessariamente de arquiteturas complexas, mas sim de um pipeline bem construído e dados relevantes.

## **3 MATERIAIS E MÉTODOS**

A construção deste estudo se fundamentou em uma abordagem quantitativa e experimental, utilizando técnicas de aprendizado supervisionado para testar a viabilidade da previsão de movimentos do Bitcoin (BTC-USD). O projeto foi desenvolvido de forma simplificada, focando na implementação de um modelo básico de rede neural artificial para analisar dados históricos deste ativo digital.

A pesquisa utilizou dados secundários obtidos de bases públicas, como o Yahoo Finance (via API yfinance), que fornece informações históricas sobre preços e indicadores financeiros. O período analisado abrangeu os últimos dois anos (2023–2025), com dados diários para capturar padrões relevantes.

### **3.1 Coleta de Dados**

A coleta de dados foi realizada por meio da biblioteca yfinance, que permitiu obter informações do Bitcoin (BTC-USD) diretamente do Yahoo Finance. Foram coletadas as seguintes variáveis:

- **Preço de fechamento diário**
- **Volume de negociação**
- **Médias móveis (SMA, EMA)**
- **Índice de Força Relativa (RSI)**

- **Volatilidade (desvio padrão de 14 dias)**
- **Volume Médio (14 dias)**

A base de dados foi composta por **aproximadamente 500 registros diários**, correspondentes aos últimos dois anos completos de negociação, garantindo uma amostra robusta e representativa para a modelagem preditiva.

A seleção dessas variáveis se baseou na literatura que aponta sua relevância para previsão de tendências de mercado (Nomad Invest, 2023), com adaptações para criptomoedas.

### **3.2 Preparação e Limpeza dos Dados**

A preparação dos dados foi uma etapa essencial para garantir a qualidade do modelo preditivo. As seguintes técnicas foram aplicadas:

- **Remoção de valores ausentes**, utilizando o método `drop()`, para evitar distorções nos resultados causadas por dados incompletos. Essa abordagem é adequada em bases de dados com poucas ausências e garante a integridade do conjunto de dados analisado.
- **Normalização com Min-Max Scaling (escala 0–1)**, aplicada a todas as variáveis numéricas, com o objetivo de manter as variáveis na mesma escala e evitar que indicadores com maior magnitude dominassem o processo de aprendizado do modelo. Essa técnica é especialmente importante em redes neurais, que são sensíveis à variação de escala entre atributos.
- **Seleção de variáveis relevantes**, priorizando indicadores amplamente referenciados na literatura por sua capacidade de captar padrões de comportamento de preços em mercados voláteis, como SMA, EMA, RSI e Volatilidade. A escolha por limitar o número de variáveis foi feita com o objetivo de reduzir a complexidade do modelo e evitar overfitting.
- **Criação da variável alvo binária (Target)**: 1 se o preço subiu no dia seguinte, 0 caso contrário. Essa modelagem segue uma abordagem comum em estudos de classificação binária no mercado financeiro, permitindo a formulação clara do problema como uma tarefa supervisionada.

Como o foco do estudo foi a construção de um modelo básico, não foram aplicadas técnicas avançadas de engenharia de atributos ou otimizações mais sofisticadas. Essa escolha foi

intencional, visando um primeiro experimento funcional e replicável no contexto de iniciação científica.

### 3.3 Construção do Modelo Supervisionado

O modelo preditivo foi desenvolvido utilizando redes neurais artificiais com TensorFlow/Keras, por sua eficácia na identificação de padrões não lineares (Medeiros e Veiga, 2019). Essa tecnologia é amplamente adotada em tarefas de classificação em finanças e se mostrou adequada para explorar os dados históricos do Bitcoin (BTC-USD). A arquitetura implementada incluiu:

- **Uma camada de entrada**, correspondente ao número de variáveis de entrada (6 indicadores técnicos), o que permitiu capturar múltiplos aspectos do comportamento do ativo de forma simultânea.
- **Duas camadas ocultas**, configuradas da seguinte forma:
  - 64 neurônios com função de ativação ReLU, seguidos de um **Dropout de 20%**, aplicado como forma de reduzir o risco de overfitting, dado o volume relativamente limitado de dados disponíveis.
  - 32 neurônios também com ativação ReLU, promovendo uma segunda transformação não linear dos dados para melhorar a capacidade de generalização do modelo.
- **Uma camada de saída**, com **1 neurônio e ativação sigmoide**, adequada para tarefas de **classificação binária**, como a previsão da direção do preço (alta ou baixa).

A rede foi compilada utilizando o **otimizador Adam**, reconhecido por sua eficiência em problemas de aprendizado profundo, junto à função de perda **binary cross entropy**, que é apropriada para classificação binária, e a **métrica de acurácia** como medida principal de desempenho.

A escolha dessa arquitetura seguiu critérios de simplicidade e eficácia, compatíveis com a proposta exploratória da pesquisa. O número reduzido de camadas e neurônios foi intencional para evitar o sobreajuste, ao mesmo tempo em que se explorou a capacidade das RNAs de capturar relações não lineares. O uso de técnicas mais avançadas, como ajustes por grid search ou tuning extensivo de hiperparâmetros, foi deliberadamente evitado neste primeiro experimento, considerando o escopo introdutório da pesquisa e seu caráter educacional.

### 3.4 Divisão dos Dados em Conjuntos de Treinamento e Teste

Para avaliar o desempenho do modelo, os dados foram divididos em:

- **70% para Treinamento** → Conjunto utilizado para ajustar os pesos do modelo.
- **30% para Teste** → Conjunto usado para avaliar a precisão das previsões.
- **Validação implícita** → 20% dos dados de treino foram usados para validação durante o treinamento.

A divisão de 70% para treinamento e 30% para teste segue uma convenção amplamente adotada em estudos exploratórios de aprendizado de máquina. Essa proporção oferece uma quantidade suficiente de dados para que o modelo aprenda padrões sem comprometer a avaliação em dados não vistos. A validação interna com 20% dos dados de treino durante o processo de ajuste ajuda a monitorar o desempenho do modelo ao longo do treinamento, prevenindo o overfitting.

Optou-se por **não utilizar validação cruzada** neste momento, visto que o objetivo central do estudo foi testar, de maneira prática e objetiva, a viabilidade da aplicação de redes neurais artificiais na previsão de tendências de preços com base em indicadores técnicos. Essa abordagem mais direta permitiu a construção de um experimento mais simples, didático e alinhado à proposta inicial da pesquisa.

### 3.5 Métricas de Avaliação

Para medir o desempenho do modelo, foram utilizadas métricas simples e interpretáveis:

- **Acurácia:** Percentual de previsões corretas.
- **Matriz de Confusão:** Para visualizar os acertos e erros do modelo.
- **Relatório de classificação** (precisão, recall, F1-score).

Essas métricas permitiram avaliar se o modelo conseguiu captar padrões no mercado financeiro e se pode ser melhorado em pesquisas futuras (Chan e Wong, 2020).

### 3.6 Ferramentas Utilizadas

O projeto foi implementado em Python (3.11), utilizando:


- **yfinance (v0.2.59)** → Para coleta de dados financeiros.
- **Pandas (v2.2.3)** e **NumPy (v2.1.3)** → Para manipulação dos dados.
- **TensorFlow (v2.19.0)** → Para construção da rede neural.
- **Matplotlib (v3.10.1)** e **Seaborn (v0.13.2)** → Para análise visual dos resultados.

## 4 RESULTADO E DISCUSSÃO

Durante a experiência, foi conduzido um experimento com Redes Neurais Artificiais (RNA) para a previsão do movimento diário de preços do ativo Bitcoin (BTC-USD), com base em indicadores técnicos previamente definidos: Média Móvel Simples (SMA), Média Móvel Exponencial (EMA), Índice de Força Relativa (RSI), Volatilidade (desvio padrão dos preços) e Média Móvel do Volume. O objetivo foi classificar se, no dia seguinte, o preço do ativo subiria ou cairia, utilizando dados históricos dos últimos dois anos.

Após o treinamento e validação do modelo, os resultados obtidos foram avaliados por meio da matriz de confusão e do relatório de classificação, ferramentas fundamentais para compreender o desempenho preditivo do algoritmo.

Figura 1: Matriz de Confusão da Classificação dos Movimentos do Bitcoin



Fonte: o autor



A matriz de confusão revelou que o modelo foi capaz de prever corretamente 47 instâncias em que o preço do Bitcoin caiu (classe 0) e 31 instâncias em que o preço subiu (classe 1). No entanto, houve 66 classificações incorretas (26 falsos positivos e 40 falsos negativos), evidenciando a limitação do modelo em identificar padrões mais consistentes de alta nos preços.

Tabela 1: Relatório de Desempenho do Modelo de Classificação

Relatório de Classificação				
	precision	recall	f1-score	support
0	0.54	0.64	0.59	73
1	0.54	0.44	0.48	71
accuracy			0.54	144
macro avg	0.54	0.54	0.54	144
weighted avg	0.54	0.54	0.54	144

Fonte: o autor

O relatório de classificação fornece uma visão quantitativa mais detalhada, com os seguintes destaques:

- A acurácia total do modelo foi de 54%, indicando que pouco mais da metade das previsões foram corretas.
- A classe 0 (queda) apresentou maior recall (0.64), sugerindo que o modelo teve maior sensibilidade em identificar dias de desvalorização do ativo. A precisão dessa classe, entretanto, foi moderada (0.54), refletindo a existência de falsos positivos.
- A classe 1 (alta) teve uma precisão semelhante (0.54), mas com recall inferior (0.44), apontando dificuldade maior na identificação correta dos dias de valorização.
- O F1-score foi de 0.59 para a classe 0 e 0.48 para a classe 1, evidenciando a assimetria no desempenho entre as classes.

Esses resultados, embora modestos, estão alinhados com o escopo do projeto, que teve como foco principal o desenvolvimento e a experimentação de um modelo preditivo baseado em inteligência artificial — e não necessariamente a obtenção de um alto desempenho na previsão do preço do Bitcoin. O mercado de criptoativos, por sua natureza altamente volátil e influenciado por inúmeros fatores externos, representa um grande desafio mesmo para modelos preditivos avançados.

A maior eficiência do modelo em prever movimentos de queda pode estar relacionada a padrões estatísticos mais frequentes nesse tipo de movimentação, enquanto os momentos de valorização podem depender de fatores não captados pelos dados técnicos utilizados.

Embora o modelo tenha obtido uma acurácia próxima ao nível da aleatoriedade (50%), esse comportamento é compatível com o que foi observado em estudos como o de Alessandretti et al. (2018), que mostraram que até mesmo algoritmos supervisionados simples conseguem superar benchmarks de aleatoriedade em tarefas preditivas envolvendo criptomoedas. Da mesma forma, Liu et al. (2023) destacam que a previsibilidade dos retornos em criptoativos é possível, embora geralmente limitada, e que os resultados variam conforme a complexidade do modelo e a diversidade dos dados utilizados.

Assim, a construção do modelo aqui proposto serviu como uma base prática e funcional para o estudo de redes neurais no contexto financeiro. Ao invés de focar em altos índices de desempenho, o projeto contribuiu com a estruturação de uma pipeline completa de coleta, processamento, modelagem e avaliação — aspectos fundamentais no desenvolvimento de soluções baseadas em IA.

Dessa forma, os resultados obtidos não devem ser interpretados como aplicáveis diretamente em contextos reais de tomada de decisão financeira, mas sim como um ponto de partida para pesquisas futuras. Estudos posteriores podem explorar melhorias como o balanceamento das classes, inclusão de variáveis externas, ajustes na arquitetura do modelo e estratégias mais robustas de validação.

## **5 CONSIDERAÇÕES FINAIS**

Retomando o objetivo deste trabalho, buscou-se desenvolver um modelo de Inteligência Artificial, mais especificamente uma Rede Neural Artificial (RNA), com o propósito de prever a

direção do movimento diário do Bitcoin (BTC-USD) — se o preço subiria ou cairia — com base em dados históricos e indicadores técnicos do mercado financeiro.

A partir da coleta e processamento de dados dos últimos dois anos, foi possível estruturar e avaliar um modelo de classificação binária. Os resultados demonstraram uma acurácia de 54%, com maior eficiência na previsão de quedas do ativo, conforme evidenciado pelas métricas de recall e F1-score da classe correspondente. Embora o desempenho tenha sido modesto, isso já era esperado, uma vez que o foco da pesquisa esteve voltado principalmente à **exploração da construção e aplicação prática de um modelo de rede neural no contexto financeiro**, e não à superação de benchmarks ou obtenção de altos índices preditivos.

O trabalho proporcionou uma experiência concreta e relevante na utilização de técnicas de aprendizado de máquina, destacando os desafios inerentes à previsão de ativos financeiros altamente voláteis, como o Bitcoin. A dificuldade do modelo em identificar padrões relacionados à valorização do ativo reforça a complexidade do problema e a necessidade de estratégias complementares.

Dentre as possíveis melhorias para trabalhos futuros, destacam-se:

- A expansão do período de coleta de dados históricos, oferecendo à rede um conjunto mais robusto e representativo de padrões;
- A inclusão de novos indicadores técnicos ou variáveis externas (como notícias ou eventos macroeconômicos), que podem enriquecer o conjunto de entradas do modelo;
- O refinamento da arquitetura da RNA, testando diferentes combinações de camadas, funções de ativação e hiperparâmetros;
- A aplicação de técnicas para balanceamento das classes e validação cruzada, de forma a melhorar a capacidade de generalização do modelo.

Assim, este estudo se estabelece como uma etapa inicial e formativa no uso de inteligência artificial aplicada ao mercado financeiro, com potencial para ser expandido em trabalhos futuros com foco em desempenho, aplicações práticas e integração de abordagens híbridas. Ao reconhecer os limites e contribuições do projeto, reforça-se o caráter exploratório e educacional desta pesquisa, sem perder de vista sua relevância na construção de soluções mais sofisticadas e eficazes no campo da análise preditiva.

# BITCOIN PRICE MOVEMENT FORECASTING USING ARTIFICIAL NEURAL NETWORKS AND TECHNICAL INDICATORS

## ABSTRACT

This study presents the application of Artificial Intelligence in Financial Investment Analysis, developed in the academic research context involving data science and the cryptocurrency market, during the months of January to April 2025. The objective of this research is to demonstrate the feasibility of using Artificial Neural Networks (ANNs) to predict the direction of Bitcoin (BTC-USD) price movements based on historical data and technical indicators. Daily price and volume data from the last two years were collected using the yfinance library, and the following indicators were calculated: Simple Moving Average (SMA), Exponential Moving Average (EMA), Relative Strength Index (RSI), price Volatility (standard deviation), and Volume Moving Average. These features were used as input for training a classification model to predict whether the next day's price would go up or down. The model was evaluated using accuracy, precision, recall, F1-score, and a confusion matrix, achieving an accuracy of approximately 54%. Despite limitations, the results suggest that neural networks can be valuable tools to support investment decision-making. This study contributes to the ongoing discussion around the application of machine learning in the financial market, particularly in the development of predictive strategies for cryptocurrencies.

## Palavras-chave:

Bitcoin. Artificial Intelligence. Neural Networks. Technical Indicators. Price Prediction

## REFERÊNCIAS

REN, Y.-S. et al. *Past, present, and future of the application of machine learning in cryptocurrency research*. Research in International Business and Finance, v. 62, p. 101799, 2022. Disponível em: <https://doi.org/10.1016/j.ribaf.2022.101799>. Acesso em: 10 jun. 2025.

LIU, Y. et al. *Forecasting cryptocurrency returns with machine learning*. Research in International Business and Finance, v. 66, p. 101905, 2023. Disponível em:

<https://doi.org/10.1016/j.ribaf.2023.101905>. Acesso em: 10 jun. 2025.

DINHEIRO NA PRÁTICA. *Algoritmos de IA que estão mudando o mercado financeiro*. 2023. Disponível em: <https://dinheironapratica.com.br/blog/algoritmos-de-ia-que-estao-mudando-o-mercado-financeiro/>. Acesso em: 17 fev. 2025.

GITHUB. *Previsão do movimento do Ibovespa*. 2023. Disponível em: <https://github.com/odiegopereira/previsao-mercado-acoes-machine-learning>. Acesso em: 17 fev. 2025.

NOMAD INVEST. *6 Índices financeiros para investidores da Bolsa*. 2023. Disponível em: <https://www.nomadglobal.com/invest/artigos/conheca-6-indices-financeiros-relevantes-para-investidores-da-bolsa>. Acesso em: 17 fev. 2025.

MURPHY, John J. *Technical analysis of the financial markets: a comprehensive guide to trading methods and applications*. New York: New York Institute of Finance, 1999.

GÉRON, Aurélien. *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: concepts, tools, and techniques to build intelligent systems*. 2. ed. Sebastopol: O'Reilly Media, 2019.